

孟昭明

Zhaoming Meng

(+86) 156-0988-5921 · 中国科学技术大学 · 网络空间安全专业 ·
mzm-0571@mail.ustc.edu.cn · troyzmz.github.io



我的研究兴趣主要集中在**大模型的可解释性与安全对齐**上。我具有严谨的工作态度与高效的时间管理能力，对科研充满热情，具备快速学习新知识的自驱力。

教育背景

至今	中国科学技术大学 · 网络空间安全学院 · 网络空间安全专业		
2023.09	GPA: 3.67 / 4.3	加权均分: 87.43	Rank: 5 / 51 (top 10%)
主修课程	人工智能原理与技术 (92)、Web 信息处理与应用 (98)、数字逻辑电路 (95)、计算机程序设计 A (95)、信号与系统 B (92)、概率论与数理统计 (91)、计算机原理与嵌入式系统 (90) 等		

专业能力

编程语言 Python, C
英语能力 CET-6 500+

获奖情况

国家励志奖学金	2026 年 03 月
第十八届全国大学生信息安全竞赛——作品赛二等奖	2025 年 08 月
优秀学生奖学金银奖(top 10%)	2024 年 11 月

科研项目

LiteGuard 端侧深伪检测 APP 队长、核心模型开发 2025 年 05 月 - 2025 年 08 月

研究背景: 深度伪造 (AI 换脸) 技术带来极大的安全风险, 现有深度伪造检测技术由于模型参数量较大, 难以在端侧上进行部署, 并且在跨数据集检测中存在泛化能力较差与虚警率较高等问题。

研究内容: 在单帧图片检测方面, 我们在 EfficientNet V2 这一轻量化模型架构的基础上通过一系列空间数据增强的手段, 实现了在帧级别极高的检测准确率 (AUC : 0.98) 及较低的虚警率 (FPR : 0.04); 在视频流检测方面, 我们通过设计特定的采样策略, 将采样后的帧序列做残差处理后再输入到 EfficientNet B0 中, 以捕捉深度伪造视频中普遍存在的时序不连贯性, 并且使用了随机帧跳跃、帧重复等时序数据增强手段, 在跨领域数据集中取得了较大的泛化性提升 (当训练集与测试集差别较大时仍能够保持 0.74 的 AUC)。相关成果获得第十八届全国大学生信息安全竞赛——作品赛二等奖并部署到荣耀手机终端。

基于 Shannon 熵的模型遗忘评估 完成主要实验及数据处理 2025 年 11 月 - 2026 年 07 月

研究背景: 现有的模型遗忘评估往往依靠模型对于遗忘集问题的输出来实现, 但这些方法往往难以判断模型的遗忘深度 (表层对齐 or 深度遗忘)。基于上述问题, 我们将信息论中的 Shannon 熵等知识引入大模型遗忘的评估中, 希望不依赖模型的输出, 而是分析模型隐空间的表征从而达到评估的目的。

研究内容: 我们创新性的使用有效秩 (eRank) 指标用以评估模型遗忘的程度。我们首先收集模型对于 answer token 部分的隐空间表征集合, 之后进行中心化和 L2 归一化并构建协方差矩阵, 通过归一化的特征值的香农熵来计算得到 eRank。在重训练以及模型量化的场景下相比于其他基于模型对于遗忘集问题的输出的指标具有更高的稳定性, 能够更好的反映模型在神经元层面上对于特定知识的遗忘程度。

实践经历

计算机程序设计 (C 语言) 课程助教 2025 年 09 月 - 2026 年 01 月